PEDIDOS · LIGANDO O BERT E O LLM

Classe de 86,7% para 97,5%, com US$ 0,30 de LLM

configuração	classe	classe · catálogo em inglês	precisão das caixas	cobertura	invenção	custo de LLM	tempo · 520 pedidos
Só regras medição oficial · o piso	**86,7%**	**15,8%**	**99,1%**	**77,7%**	**2/16**	**US$ 0,00**	**2 s**
+ BERT modelo local, sem custo por chamada	**86,7%**	**15,8%**	**99,1%**	**82,2%**	**2/16**	**US$ 0,00**	**28 s**
+ LLM no resíduo 37 pedidos em dúvida, escolhendo da lista do PDM	**86,7%**	**15,8%**	**99,1%**	**84,2%**	**3/16**	**US$ 0,17**	**76 s**
+ classes pelo LLM 5 regras aprendidas sem ver o gabarito	**92,5%**	**52,6%**	**99,0%**	**91,0%**	**3/16**	**US$ 0,24**	**27 s**
+ classes pelo LLM 11 regras, todos os pedidos (operação real)	**97,5%**	**84,2%**	**99,1%**	**96,2%**	**3/16**	**US$ 0,30**	**28 s**

BERT: não mexe na classe, que é decidida pelo substantivo. Preenche as caixas que as regras deixaram vazias: cobertura de 77,7% para 82,2%, sem perder precisão.

LLM no resíduo: resolve as ambíguas e os conflitos entre regra e BERT, escolhendo só da lista do PDM. As caixas ambíguas perdidas vão de 10 para 0.

Classes pelo LLM: ataca o catálogo em inglês, de onde vinham os 16 erros. Mesmo aprendendo sem ver o gabarito, a classe vai a 92,5%.

O custo total é de US$ 0,30 para os 520 pedidos, menos de um décimo de centavo de dólar por pedido. A invenção subiu de 2 para 3 em 16: o LLM preencheu um acabamento que o pedido não informava. O gabarito é o mesmo da medição oficial e continua provisório até a revisão humana.

fonte: artefatos/medicao_pedidos/*/resultado.json e execucao.log · evaluate_pedidos.py · Haiku 4.5 no Bedrock

PEDIDOS · O LLM ESCREVEU AS REGRAS

O LLM traduziu 11 nomes de classe e gravou cada um como regra

termo do catálogo	sujeito do PDM	classe	pedidos
`HEX HEAD BOLT` `SEM GABARITO`	PARAFUSO SEXTAVADO	**PDM001**	**5**
`HYDRAULIC HOSE ASSEMBLY` `SEM GABARITO`	MANGUEIRA HIDRAULICA MONTADA	**PDM011**	**4**
`BALL VALVE` `SEM GABARITO`	VALVULA ESFERA	**PDM040**	**2**
`GATE VALVE` `SEM GABARITO`	VALVULA GAVETA	**PDM041**	**2**
`CHECK VALVE`	VALVULA RETENCAO	**PDM043**	**1**
`ELECTRIC CABLE FLEXIVEL`	CABO ELETRICO	**PDM060**	**1**
`FLAT GASKET`	JUNTA PLANA	**PDM034**	**1**
`OIL SEAL`	RETENTOR	**PDM032**	**1**
`PRESSURE GAUGE` `SEM GABARITO`	MANOMETRO	**PDM067**	**1**
`SPHERICAL ROLLER BEARING`	ROLAMENTO AUTOCOMPENSADOR ROLOS	**PDM021**	**1**
`TWIST DRILL HSS`	BROCA HELICOIDAL	**PDM082**	**1**

Como funciona

O LLM é chamado **uma vez por texto recusado**, lê a expressão inteira (`BALL VALVE` é VALVULA ESFERA, não "bola") e escolhe só da lista fechada de sujeitos do PDM. A resposta vira regra em `sujeito_aprendido.json`. Na rodada seguinte: **0 chamadas**, o dicionário resolve.

Travas: barradas antes de virar regra

- `SOCKET WELD` → ADAPTADOR
  aparece em 94 textos da base
- `SOCKET WELD` → ADAPTADOR ou NIPLE
  o mesmo termo recebeu sujeitos diferentes

Também barra regra que não reproduz a classe no próprio texto ou que não está escrita nele. 15 pedidos foram confirmados como fora do PDM (serviço, café, móvel).

Erros que sobraram (3 de 120): `Pipe fitting` foi barrado pela trava e ficou para revisão humana; o LLM respondeu "nenhuma classe" para `Safety glove`, que é LUVA SEGURANCA; e `Socket head cap screw` já caía em CAP no piso, porque a palavra inglesa "cap" casa com o tampão de tubo. Nenhuma regra nova causou erro.

fonte: artefatos/medicao_pedidos/sujeito_aprendido_*.json · scripts/24_aprender_classes_llm.py · 38 perguntas, US$ 0,13