CUSTO DE IA · O QUE GASTAMOS E O QUE GASTARÍAMOS

US$ 40,35 de LLM nesta base. Com LLM em tudo: US$ 228,59

> **5,7×** mais caro por execução — e 8,4× na tarefa que as duas abordagens fazem igual, ler atributo e decidir classe (US$ 19,90 medidos contra US$ 168,08 estimados). Por registro, US$ 0,00171 contra US$ 0,00970.

Gasto real — perguntas que de fato foram feitas 🟢

etapa	perguntas	custo
11 · canonizar termos que o PDM recusou	**939**	**US$ 1,32**
10 · desempate de CONFLITO e AMBÍGUO	**1.370**	**US$ 5,53**
12 · detecção de dado genérico (caixas com sinal)	**1.919**	**US$ 2,92**
12 · detecção de dado genérico (todas as caixas)	**6.382**	**US$ 9,83**
08 · preencher FABRICANTE nos faltantes (Sonnet 5, em lote)	**12.909**	**US$ 20,45**
24 · aprender tradução de classe (catálogo em inglês)	**38**	**US$ 0,13**
04 · os 520 pedidos com todas as camadas ligadas	**38**	**US$ 0,17**
total em produção	**23.595**	**US$ 40,35**

Fora da tabela, porque é pesquisa e não operação: o benchmark das 10 soluções × 4 campos custou US$ 173,62, uma vez só, para descobrir qual solução ganha em cada campo. Num cliente novo não se repete.

Se o LLM fosse a única camada, nos mesmos 23.554 registros 🟡

o que o LLM faria	perguntas	custo
atributos, 1 pergunta por registro	**23.517**	**US$ 112,10**
classe, contra a lista fechada do PDM	**23.554**	**US$ 55,98**
FABRICANTE em toda linha	**23.554**	**US$ 16,17**
REFERENCIA_FABRICANTE em toda linha	**23.554**	**US$ 10,13**
NCM em toda linha	**23.554**	**US$ 18,10**
GRUPO_MERCADORIA em toda linha	**23.554**	**US$ 16,11**
total, uma execução, mesmo modelo	**141.287**	**US$ 228,59**

O modelo multiplica

haiku-4-5	**US$ 228,59**
sonnet-5	**US$ 457,17**
opus-5	**US$ 1 142,94**
fable-5	**US$ 2 285,87**

A reexecução multiplica

Hoje a 2ª execução da mesma base custa **US$ 0,00**: a resposta virou regra no dicionário e o cache devolve a pergunta repetida. Sem camada barata, **US$ 457,18** pelas duas rodadas do teste de determinismo.

O desconto que falta aos dois

Com *prompt caching* por classe o contrafactual cairia a **US$ 116,35**. Não está implementado, e valeria igual para o resíduo: a razão se mantém.

fonte: artefatos/custo_llm.json · scripts/27_custo_llm.py · docs/16-custo-de-llm.md · Haiku 4.5 no Bedrock, preço de tabela

CUSTO DE IA · ONDE O LLM NÃO VALE O PREÇO

Em 3 dos 4 campos de identidade, a solução barata *acerta mais*

campo	solução aplicada	top-1	na base inteira	top-1 do LLM	LLM na base inteira
REFERENCIA_FABRICANTE	`regras`	**0,844**	**US$ 0,00**	**0,811**	**US$ 10,13**
NCM	`tfidf_lr`	**0,910**	**US$ 0,00**	**0,887**	**US$ 18,10**
GRUPO_MERCADORIA	`knn_cohere`	**0,966**	**US$ 1,09**	**0,965**	**US$ 16,11**
FABRICANTE	`llm_fewshot_sonnet`	**0,843**	**US$ 46,40**	**0,833**	**US$ 16,17**

Se o LLM em tudo fosse só mais caro, seria escolha de orçamento. O benchmark diz outra coisa: em 3 dos 4 campos, pagar pelo LLM compraria **menos acerto**. Só em FABRICANTE ele ganha — e ali o projeto pagou pelo modelo melhor (Sonnet 5), que é metade do gasto real do projeto. A arquitetura não economiza por avareza: paga o LLM onde ele é o melhor e não paga onde ele perde.

> **O que este slide não prova.** A comparação de acerto é dos quatro campos de identidade, que têm gabarito e benchmark. Nos *atributos* o contrafactual mede custo, não acurácia: rodar 500 registros com o LLM fazendo tudo (~US$ 5) fecharia essa lacuna, e é a próxima medição da lista.

Como o contrafactual foi calculado

O script monta o **prompt de verdade** para cada um dos 23.554 registros — o mesmo `SISTEMA`, o mesmo `enum` da classe no tool use — e converte caractere em token por uma razão **medida**: a única rodada do projeto com tokens em log (37 chamadas, 125.402 tokens de entrada) dá **2,1068 caracteres por token**.

A convenção de 3,5 car/token dos scripts 12 e 24 conta 40% menos token do que o real, e toda estimativa de `--so-contar` sai baixa na mesma proporção.

Aferição contra medição real

O item "atributos" é a mesma chamada do desempate, só que em todos os registros. Os dois custos por registro batem:

contrafactual, atributos 🟡	**US$ 0,00477**
desempate real, 1.370 registros 🟢	**US$ 0,00404**

Os 18% de diferença têm o sinal certo: no contrafactual o modelo preenche **todas** as caixas, e escreve mais na saída.

O LLM sem o andaime das camadas

O mesmo modelo, perguntado sem lista fechada, sem *tool use* e sem validador (`llm_naive`), tira top-1 de **0,000** em GRUPO_MERCADORIA e **0,025** em NCM — e custa quase o mesmo. O que faz o LLM servir não é o modelo, é o andaime em volta dele.

fonte: preenchimento/benchmark.csv (10 soluções × 4 campos, tokens reais) · artefatos/custo_llm.json · docs/16-custo-de-llm.md