PEDIDOS · O QUE CHEGA, NÃO O QUE JÁ ESTÁ

O gabarito mediu a base. O pedido é outra coisa.

	base	pedido
registros	23.554 materiais	520 pedidos
formato do texto	uma coluna de descrição	4 formatos · 3 canais de entrada
caixa alta	praticamente toda a base	519 dos 520 têm minúscula
onde está a informação	na própria linha	136 trazem o dado só no anexo
língua	português	29 em inglês (catálogo do fornecedor)
o problema	campo vazio: 78,5% da referência do fabricante	campo vazio é raro: 2,8% das caixas

Medir na base não diz como o pipeline se comporta na **entrada**, que é onde o cadastro é decidido. Daí um gabarito próprio: 120 pedidos sorteados, 562 rótulos de caixa e 120 de classe, anotados só contra o texto cru e o PDM.

fonte: avaliacao/GABARITO_PEDIDOS.md · dados/02_pedidos_cadastro.xlsx

ACERTO DE CLASSE · POR FORMATO DE ENTRADA

Os erros de classe estão num canal só

escala 0–100% · rótulo direto em cada barra · n e IC 95% no hover do HTML e em resultado_pedidos.md



Os três formatos em português dão 100%. O catálogo fica em 15,8% [5,5–37,6%], e é de onde vêm **16 dos 16** erros. A causa é a língua: essas linhas chegam em inglês (`Ball valve`, `Hex head bolt`, `Oil seal`), o pipeline não acha o substantivo do PDM e conclui FORA_DO_PDM. Os acertos do canal confirmam — são `O-ring`, que coincide com o qualificador do PDM, e um item com os atributos em português.

> 29 dos 520 pedidos (5,6%) entram por esse canal e seriam recusados por causa da língua. É conserto de vocabulário, não de modelo.

fonte: avaliacao/resultado_pedidos.md §1 · gold_classe_pedidos.csv

PEDIDOS · MEDIDO EM GABARITO

Afirma pouco, e erra quase nada

Acerto de classe

86,7%

104 de 120 pedidos · IC 79,4–91,6%

Precisão das caixas

99,1%

420 de 424 valores afirmados · IC 97,6–99,6%

Cobertura, classe certa

92,0%

77,7% no total; o resto se perde porque a classe errou

Invenção · estrita

2/16

caixas vazias preenchidas · IC 3,5–36,0%. Na leitura permissiva, 2/16

Caixas perdidas

122

85 por classe errada, 27 "não informado", 10 ambíguas

Concordância A×B · kappa

0,984

11 divergências adjudicadas — mas **não** são dois anotadores independentes

Ressalva de método. As duas passadas de anotação são do mesmo anotador — um LLM — sob regras de decisão diferentes, e não de duas pessoas. O kappa mede quanto a *regra* muda o rótulo, não concordância entre duas cabeças. Até `revisao_humana_pedidos.csv` voltar respondido, o gabarito é provisório. Execução medida sem BERT e sem LLM: são números do piso.

fonte: avaliacao/resultado_pedidos.json · concordancia_pedidos.json

PEDIDOS · QUATRO DEFEITOS COM NOME E LINHA

Cada número aponta um conserto

defeito	tamanho	o que acontece
Vocabulário só em português	16 erros de classe	29 pedidos do canal de catálogo chegam em inglês e viram FORA_DO_PDM; cada recusa arrasta as caixas do item (85 das 122 perdidas)
Referência do fabricante não é extraída	25 caixas	com a classe certa e o código visível no texto (`hb-467508` , `g2021` , `C 83 416`). Em PDM100 e PDM110 esse campo é metade da chave de identidade da regra 10
Irmãos de grandeza	2 invenções + 8 ambíguas	caixa vazia recebe o valor da irmã (terminal A copiado para B; a seção virando também diâmetro interno); e o espelho, dois terminais no texto que o pipeline não sabe separar
Camada `ordem_pdm`	0 de 3 certos	nas correias, pôs o comprimento externo na caixa `REFERENCIA` , que devia levar a designação da correia (`A157` , `B146` , `SPB 3650`)

Nenhum deles é "o modelo precisa melhorar". Os quatro têm arquivo, linha e teste possível — e o primeiro vale mais que os outros três somados.

fonte: avaliacao/resultado_pedidos.md §3 a §5