HACKATHON VX · DESAFIO 01 · CADASTRO E SANEAMENTO

# Pipeline de saneamento

Como 23.554 materiais em texto livre viram grades de caixas comparáveis, e por que duas grades iguais provam um código redundante.

vxwinners · novembro de 2026

VISÃO GERAL

# Mesmas caixas, mesmo item

entrada

## Base

Texto livre, 22 anos de deriva, seis plantas

**23.554**

materiais, PDM com 44 classes

passo 1

## Classe

O grupo reduz 44 classes a 1–3; o substantivo decide

**90,8%**

acerto de classe

passo 2

## Caixas

A classe define as caixas; regras e BERT as preenchem

**97,5%**

precisão dos atributos

passo 3

## Árbitro

Tudo passa pela lista do PDM; acordo dá confiança

**92,6%**

cobertura do que o texto traz

passo 4

## LLM

Só nas caixas em dúvida, nunca no dado ausente

**3.482**

itens para decisão humana

passo 5

## Junção

Chave igual: código redundante

**98,5%**

precisão da junção

NA PLATAFORMA

Fila · **3.482 itens**

Juntados · **1.991 grupos**

NCM trocado · **1.104**

Radar · **R$ 30,24 mi**

fonte: artefatos/radar.json · docs/04-como-funciona.md

PRECEDÊNCIA NÃO É EXECUÇÃO

# Toda camada que pode contribuir roda. A precedência resolve depois.

Quem ganha um empate é uma pergunta; quem roda é outra. Tratar as duas como a mesma coisa escondia divergências e produziu quatro bugs da mesma família.

fonte: docs/09-pipeline-correto.md §2

ORDEM DE EXECUÇÃO

# As cinco fases

| | | |
|---|---|---|
| fase 1<br>**Coleta** | Cada camada aplicável propõe um candidato para cada caixa, sem saída antecipada. | sai: **0 a N candidatos por caixa**, com fonte e evidência |
| fase 2<br>**Validação** | Todo candidato passa pelo validador do PDM, venha de onde vier. O recusado vira termo para o dicionário. | sai: **candidatos válidos** e termos a canonizar |
| fase 3<br>**Arbitragem** | Concordam: aceita. Discordam: vence o mais forte e a caixa sobe. Nenhum válido: pendente. | sai: **ACEITO**, **CONFLITO** ou **PENDENTE** |
| fase 4<br>**Escalada** | O LLM entra só nas caixas não resolvidas, por termo distinto, e alimenta o dicionário aprendido. | sai: **valor escolhido entre alternativas**, validado de novo |
| fase 5<br>**Portão e saída** | Monta a descrição na ordem do PDM, resolve unidade e NCM e calcula a chave de identidade. | sai: **registro saneado e chave**, ou o motivo de não fechar |

fonte: docs/09-pipeline-correto.md §3 · src/saneamento/pipeline.py

QUEM DECIDE · DA EVIDÊNCIA MAIS FORTE À MAIS FRACA

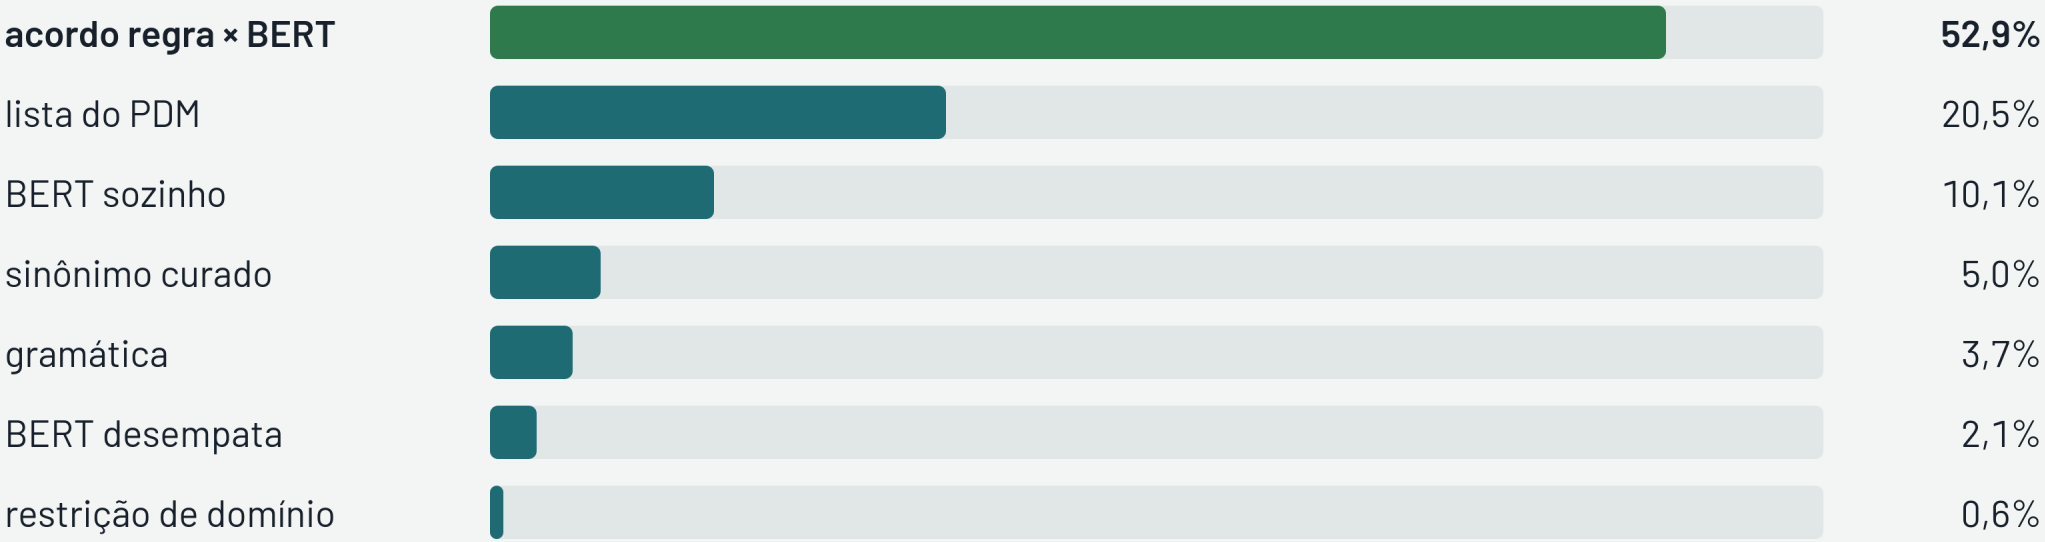
# Onze camadas, ordenadas pelo que o cadastro escreveu

| # | Camada | Exemplo | Quando roda |
|---|---|---|---|
| 0 | Rótulo no texto | DIAMETRO INTERNO:39MM | sempre |
| 1 | Lista do PDM | DIN 933 aparece literal e está na lista | sempre |
| 2 | Sinônimo curado | ACO CARB → ACO CARBONO | se 0 e 1 falham |
| 3 | Dicionário aprendido | BICROMATIZADO → ZINCADO AMARELO | se 0 a 2 falham |
| 4 | Gramática de grandeza | 1960 psi → 135,1BAR | sempre, em caixa numérica |
| 5 | Restrição de domínio | alojamento > eixo > largura | quando a contagem casa |
| 6 | Regra 2 do PDM | M12X50 → BITOLA M12 + 50MM | sempre |
| 7 | Coluna do ERP | FABRICANTE = METSO | sempre |
| 8 | BERT | recorta qual trecho é de qual caixa | sempre |
| 9 | Embedding | trecho ≈ valor permitido, com margem | só propõe candidato |
| 10 | LLM | escolhe entre alternativas | só na escalada |

fonte: docs/09-pipeline-correto.md §1 e §4

DE ONDE VEM CADA VALOR ACEITO

# Metade dos valores vem de acordo entre regra e BERT

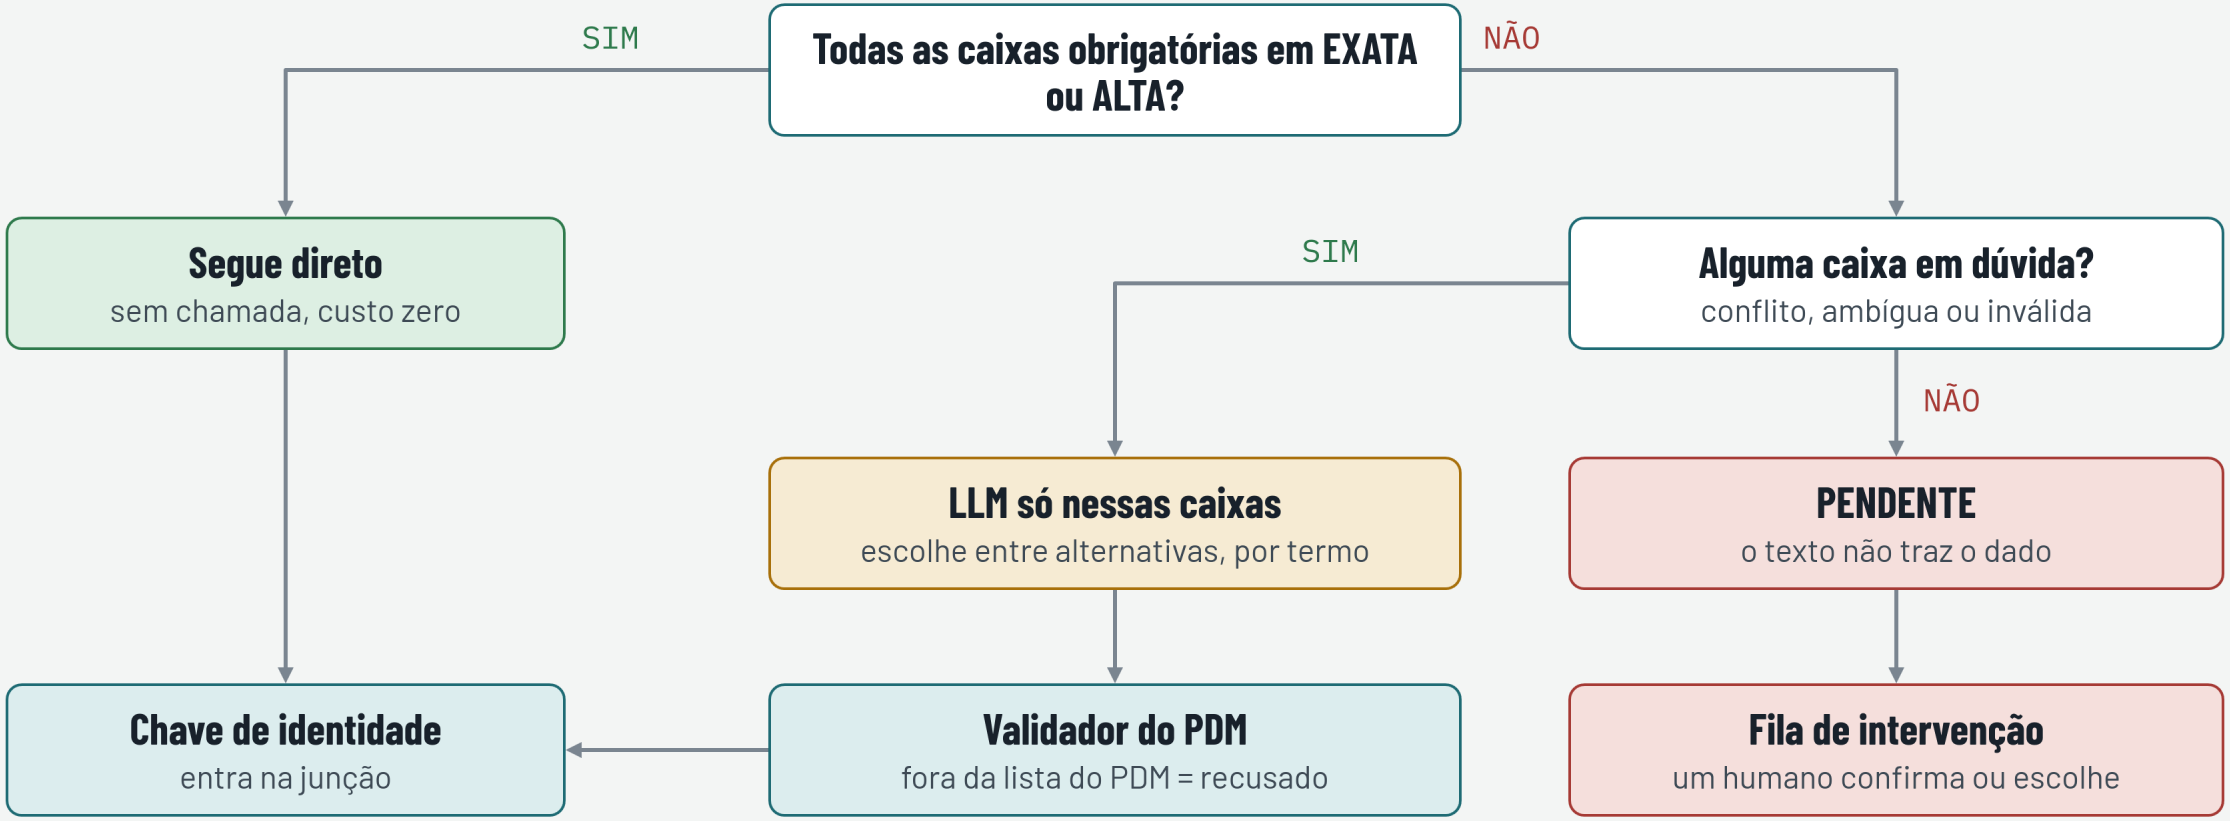



Esse sinal só existe porque o BERT roda mesmo quando a regra já achou o valor.

escala 0–60% · medição com o BERT ligado, antes das últimas correções · docs/00-estado-do-projeto.md §2

ESCALADA

# Quando o LLM é chamado, e quando não é




fonte: docs/04-como-funciona.md §7 · src/saneamento/pipeline.py (ESTADOS_ESCALAVEIS)

BANDAS DE CONFIANÇA

# A folga sobre o segundo lugar decide

| Banda | Significa | Acontece |
|---|---|---|
| EXATA | o valor da lista estava escrito no texto | aceita, sem LLM |
| ALTA | similaridade alta e com folga sobre o 2º | aceita, sem LLM |
| BANDA_LLM | parece bater, mas sem folga | chama o LLM |
| BAIXA | não bate com nada | pendência |
| VAZIA | o texto não informa | pendência |

## Trava de gêmeo numérico

| par que nunca pode confundir | similar. |
|---|---|
| INOX 304 × 316 | 0,963 |
| ROSCA NPT × BSP | 0,965 |
| DIN 931 × 933 | 0,959 |

Se o 1º e o 2º colocados diferem só por um número, o embedding nunca decide.

fonte: docs/04-como-funciona.md §6

JUNÇÃO

# Duplicidade é igualdade de chave

```
16220310 PARAFUSO SEXTAVADO, ROSCA:ROSCA GROSSA, ROSCA:M12, COMPRIMENTO:75,0MM, GRAU:8.8...
```

```
16686120 PARAFUSO SEXTAVADO; ROSCA: METRICA GROSSA; BITOLA: M12; COMPRIMENTO: 75MM...
```

| caixa obrigatória | 16220310 | 16686120 |
|---|---|---|
| Rosca | METRICA GROSSA | METRICA GROSSA |
| Bitola | M12 | M12 |
| Comprimento | 75MM | 75MM |
| Classe resistência | 8.8 | 8.8 |
| Material | ACO CARBONO | ACO CARBONO |
| Acabamento | OXIDADO PRETO | OXIDADO PRETO |
| Norma | DIN 931 | DIN 931 |

### Chave idêntica nos dois

```
PDM001 | PARAFUSO | ROSCA=METRICA GROSSA | BITOLA=M12 | COMPRIMENTO=75MM | CLASSE=8.8 | MATERIAL=ACO CARBONO | ACABAMENTO=OXIDADO PRETO | NORMA=DIN 931
```

Mesma chave, mesmo item. Nenhum modelo opinou.

fonte: docs/04-como-funciona.md §8

JUNÇÃO

# Duas formas de identidade e uma armadilha

## Especificação técnica

42 classes: parafuso, válvula, cabo... Chave = classe + sujeito + **todas** as caixas obrigatórias.

## Referência do fabricante

Filtros e sobressalentes, 37% da base. Chave = classe + sujeito + **fabricante + part number**.

## Falta uma caixa: a chave não fecha

Sem material, um parafuso de aço carbono e um de inox ficariam iguais. A chave responde "não sei".

## Equivalência não é duplicidade

`CAT 1R-1808 · DONALDSON P551808`

Intercambiáveis, mas dois produtos e dois contratos. A similaridade junta e erra; a chave separa, porque o fabricante faz parte dela.

fonte: docs/04-como-funciona.md §8 · regras 10 e 13 do PDM

CAMPOS VAZIOS · FABRICANTE, PART NUMBER, NCM

# Regras primeiro, LLM só no resto

US$ 0

## Regras e léxico

**84,4%**

acerto em part number

Part number é extração, não classificação. Em fabricante, acerta 99,9% do que cobre.

US$ 0

## TF-IDF + regressão

**91,1%**

NCM top-1 · 98,9% top-3

Os 1.173 NCMs vazios preenchidos, com 3 minutos de treino.

US$ 20,45

## LLM few-shot

**12.909**

fabricantes pelo Sonnet

Lista fechada e 3 exemplos. Antes dele, 2.765 saíram do léxico a custo zero.

fonte: README.md · preenchimento/08_preencher.py · preenchimento/saida/

BENCHMARK · 10 SOLUÇÕES × 4 CAMPOS · SPLIT CONGELADO

# O vencedor quase sempre é o mais barato

| solução · acerto top-1 | Grupo | NCM | Fabricante | Referência | Custo |
|---|---|---|---|---|---|
| regras | 96,2% | 46,9% | 73,9% | 84,4% ★ | $0 |
| tfidf_lr | 96,5% | 91,1% ★ | 82,2% | 6,1% | $0 |
| llm_fewshot_sonnet | 96,6% ★ | 87,3% | 84,3% ★ | 81,2% | $15,26 |
| llm_fewshot_fable | 96,5% | 90,4% | 84,1% | 82,6% | $69,54 |
| llm_naive_sonnet | 0,0% | 42,7% | 78,1% | 80,6% | $8,00 |
| llm_naive_fable | 0,0% | 76,7% | 79,4% | 79,7% | $72,22 |

**O ganho está na lista fechada.** Sem o vocabulário, o LLM faz 0,0% em grupo; com a lista e três exemplos, 96,6%.

**Modelo maior não compensa.** Em NCM, o modelo clássico de custo zero supera todas as LLMs.

★ vencedor do campo · fonte: preenchimento/benchmark.csv · custo total do benchmark US$ 173,62

RESULTADO · CAPITAL EM ESTOQUE

# O plano de junção está pronto

Capital consolidável

**R$ 30,24 mi**

15,1% dos R$ 200,87 mi em estoque. 2.676 códigos a bloquear em 1.991 grupos.

Na fila de intervenção

**R$ 10,84 mi**

3.482 itens esperando decisão; 1.478 se resolvem com um clique.

Já consolidado

**R$ 0,00**

Nenhuma unificação foi executada no ERP ainda.

fonte: artefatos/radar.json · plano_juncao.csv · fila_intervencao.json

RESULTADO · MEDIDO EM GABARITO

# O que está medido, e o que ainda não

Precisão das características

**97,5%**

IC 95% de 96% a 98%, em 1.131 rótulos

Junção: precisão / recall

**98,5% / 97,0%**

65 certas e 1 errada em 66 pares

Acerto de classe

**90,8%**

218 de 240 itens

Cobertura

**92,6%**

dos valores que o texto traz

Taxa de invenção · a melhorar

**23%**

19 de 84 ausentes preenchidos; 7% com as travas, só em replay

Determinismo

**idêntico**

2 execuções, 23.554 registros, nenhuma diferença

fonte: artefatos/radar.json (08/11/2026) · avaliacao/gold_*.csv · scripts/17_testar_determinismo.sh

PEDIDOS · O QUE CHEGA, NÃO O QUE JÁ ESTÁ

# O gabarito mediu a base. O pedido é outra coisa.

| | base | pedido |
|---|---|---|
| **registros** | 23.554 materiais | 520 pedidos |
| **formato do texto** | uma coluna de descrição | 4 formatos · 3 canais de entrada |
| **caixa alta** | praticamente toda a base | 519 dos 520 têm minúscula |
| **onde está a informação** | na própria linha | 136 trazem o dado só no anexo |
| **língua** | português | 29 em inglês (catálogo do fornecedor) |
| **o problema** | campo vazio: 78,5% da referência do fabricante | campo vazio é raro: 2,8% das caixas |

Medir na base não diz como o pipeline se comporta na **entrada**, que é onde o cadastro é decidido. Daí um gabarito próprio: 120 pedidos sorteados, 562 rótulos de caixa e 120 de classe, anotados só contra o texto cru e o PDM.

fonte: avaliacao/GABARITO_PEDIDOS.md · dados/02_pedidos_cadastro.xlsx

ACERTO DE CLASSE · POR FORMATO DE ENTRADA

# Os erros de classe estão num canal só

escala 0–100% · rótulo direto em cada barra · n e IC 95% no hover do HTML e em resultado_pedidos.md




**Os três formatos em português dão 100%.** O catálogo fica em 15,8% [5,5–37,6%], e é de onde vêm **16 dos 16** erros. A causa é a língua: essas linhas chegam em inglês (`Ball valve`, `Hex head bolt`, `Oil seal`), o pipeline não acha o substantivo do PDM e conclui FORA_DO_PDM. Os acertos do canal confirmam — são `O-ring`, que coincide com o qualificador do PDM, e um item com os atributos em português.

> 29 dos 520 pedidos (5,6%) entram por esse canal e seriam recusados por causa da língua. É conserto de vocabulário, não de modelo.

fonte: avaliacao/resultado_pedidos.md §1 · gold_classe_pedidos.csv

PEDIDOS · MEDIDO EM GABARITO

# Afirma pouco, e erra quase nada

Acerto de classe

**86,7%**

104 de 120 pedidos · IC 79,4–91,6%

Precisão das caixas

**99,1%**

420 de 424 valores afirmados · IC 97,6–99,6%

Cobertura, classe certa

**92,0%**

77,7% no total; o resto se perde porque a classe errou

Invenção · estrita

**2/16**

caixas vazias preenchidas · IC 3,5–36,0%. Na leitura permissiva, 2/16

Caixas perdidas

**122**

85 por classe errada, 27 "não informado", 10 ambíguas

Concordância A×B · kappa

**0,984**

11 divergências adjudicadas — mas **não** são dois anotadores independentes

**Ressalva de método.** As duas passadas de anotação são do mesmo anotador — um LLM — sob regras de decisão diferentes, e não de duas pessoas. O kappa mede quanto a *regra* muda o rótulo, não concordância entre duas cabeças. Até `revisao_humana_pedidos.csv` voltar respondido, o gabarito é provisório. Execução medida sem BERT e sem LLM: são números do piso.

fonte: avaliacao/resultado_pedidos.json · concordancia_pedidos.json

PEDIDOS · QUATRO DEFEITOS COM NOME E LINHA

# Cada número aponta um conserto

| defeito | tamanho | o que acontece |
|---|---|---|
| **Vocabulário só em português** | 16 erros de classe | 29 pedidos do canal de catálogo chegam em inglês e viram FORA_DO_PDM; cada recusa arrasta as caixas do item (85 das 122 perdidas) |
| **Referência do fabricante não é extraída** | 25 caixas | com a classe certa e o código visível no texto ( `hb-467508` , `g2021` , `C 83 416` ). Em PDM100 e PDM110 esse campo é metade da chave de identidade da regra 10 |
| **Irmãos de grandeza** | 2 invenções + 8 ambíguas | caixa vazia recebe o valor da irmã (terminal A copiado para B; a seção virando também diâmetro interno); e o espelho, dois terminais no texto que o pipeline não sabe separar |
| **Camada `ordem_pdm`** | 0 de 3 certos | nas correias, pôs o comprimento externo na caixa `REFERENCIA` , que devia levar a designação da correia ( `A157` , `B146` , `SPB 3650` ) |

Nenhum deles é "o modelo precisa melhorar". Os quatro têm arquivo, linha e teste possível — e o primeiro vale mais que os outros três somados.

fonte: avaliacao/resultado_pedidos.md §3 a §5

MODELO DE NEGÓCIO · O QUE O CLIENTE GANHA

# O cliente recupera 15× o que paga no primeiro ano

Capital consolidável — MEDIDO

**R$ 30,24 mi**

15,1% dos R$ 200,87 mi em estoque, preso em códigos redundantes.

Custo de oportunidade — PREMISSA

**R$ 9,07 mi /ano**

o que esse capital custa parado, a 30% a.a. (parâmetro do radar).

Ponte entre plantas — MEDIDO

**R$ 1,1–2,3 mi**

74 itens parados há +2 anos numa planta e zerados noutra que os movimenta. Maior caso: Tambor Retorno Continental CT9903627, R$ 780,50 mil no CD com a mina zerada.

Preço no ano 1 — PREMISSA

**R$ 593 mil**

saneamento (23.554 registros × R$ 15) + assinatura de R$ 20 mil/mês.

Retorno no ano 1

**15×**

custo de oportunidade ÷ preço: o preço se paga em 0,8 mês de capital liberado.

NCM corrigido — MEDIDO

**1.104**

contra a tabela vigente: risco fiscal que sai da base sem projeto separado.

**Ressalva.** A Serra Azul é fictícia: todo número medido vale nesta base. O que se leva a outro cliente é o método, e a razão de 15,1% do estoque, que dimensiona o ganho de cada empresa com o estoque dela.

fonte: artefatos/radar.json · plano_juncao.csv × 01_base_materiais.xlsx · premissas em 17_slides_mercado_html.py

MODELO DE NEGÓCIO · TRÊS RECEITAS

# O saneamento abre a porta; o cadastro sustenta o contrato

| camada | natureza | como cobra | na Serra Azul |
|---|---|---|---|
| **Saneamento** | projeto, uma vez: limpa a base de 22 anos | por registro saneado (R$ 15) | R$ 353 mil uma vez |
| **Modo de cadastro** | operação contínua: 1.031 cadastros novos por ano, constante há 5 anos; inclui a ponte entre plantas | assinatura mensal | R$ 240 mil por ano |
| **Rede entre empresas · visão** | a sobra de um cliente vira oferta para outro; a chave de identidade é o que torna os estoques comparáveis | comissão de 5% por transação | depende de vários clientes na mesma rede |

Sem o controle de entrada, a base volta a sujar a 1.031 itens por ano e o ganho do saneamento se perde. O saneamento vende, o cadastro mantém o cliente, e cada cliente novo deixa a rede mais valiosa para os outros.

> **Margem.** A IA quase não pesa no custo: os 12.909 fabricantes preenchidos por LLM custaram **US$ 20,45**, e as regras de custo zero resolvem o resto antes de chamar o modelo.

fonte: docs/03-analise-mercado.md §5 e §9 · README.md · premissas em 17_slides_mercado_html.py

TAMANHO DE MERCADO · TAM, SAM E SOM

# Só a Petrobras tem 42 Serras Azuis em materiais

**TAM** **US$ 18,6 bi /ano**

**Mercado global de gestão de dados mestres (MDM), 2025.** É a categoria onde o produto compete. Os institutos divergem: US$ 5 a 23 bi conforme o instituto. EXTERNO

**SAM** **R$ 48 mi /ano**

**200 industriais multiplanta no Brasil** (mineração, energia, óleo e gás, siderurgia, celulose) × assinatura, mais R$ 71 mi em projetos de saneamento. Piso: o preço é o de um cliente do porte da Serra Azul. PREMISSA

**SOM** **R$ 2,4 mi /ano**

**10 clientes no ano 3**, em receita recorrente, mais R$ 3,5 mi em projetos de saneamento acumulados. PREMISSA

Petrobras · materiais e suprimentos EXTERNO

## R$ 8,39 bi

31/12/2024. A Serra Azul tem R$ 200,87 mi.

Vale · estoque de consumo EXTERNO

## US$ 988 mi

31/12/2024. Petróleo e mineração: dois setores do perfil, cada um com bilhões em materiais de manutenção.

Duplicidade · outros medidores EXTERNO

## 10 a 20%

do estoque em operações multiplanta (Verusen) e 5 a 7% das compras de MRO (Verdantis). Aqui: 15,1%.

fonte: fortunebusinessinsights.com/master-data-management-market-114277 · Petrobras, DF 4T24 (6-K, SEC), nota de estoques · Vale, 20-F 2024, nota 13 · verusen.com · verdantis.com

CONCORRÊNCIA · POR QUE AGORA

# O mercado já paga por isso. Ninguém lê o texto em português

| alternativa | o que faz | o que falta |
|---|---|---|
| **SAP MDG e módulos de ERP** | fluxo de aprovação do cadastro | garante que o campo foi preenchido, não que está certo; não lê texto livre |
| **Informatica, Stibo e plataformas de MDM** | governam, versionam e casam registros | o casamento é por similaridade de texto, que acha 0 dos 2 grupos de duplicidade plantados no gabarito |
| **Especialistas em MRO (Verdantis, Verusen, SPARETECH)** | limpeza e enriquecimento de peças com IA | foco em inglês e catálogo global; não trazem NCM nem o PDM do cliente. Mostram que existe quem pague: a SPARETECH captou Série A com a Insight Partners |
| **Consultoria e BPO de cadastro** | equipe limpa a base em projeto | resolve o passivo e vai embora; a base volta a sujar |
| **vxwinners** | lê texto industrial abreviado em português, contra o PDM | duplicidade por igualdade de chave, auditável; NCM; equivalência não é duplicidade; pendência em vez de palpite |

**Por que agora.** Ler `FILTRO P551808 DONALDSON` e separar part number de fabricante era trabalho de especialista. Com modelos de linguagem restritos à lista do PDM, custa centavos e dá para medir em gabarito. A reforma tributária (CBS/IBS) aumenta o custo de NCM errado.

fonte: docs/03-analise-mercado.md §4, §7 e §8 · insightpartners.com (Série A da SPARETECH)