HACKATHON VX · DESAFIO 01 · CADASTRO E SANEAMENTO

Pipeline de saneamento

Como 23.554 materiais em texto livre viram grades de caixas comparáveis, e por que duas grades iguais provam um código redundante.

vxwinners · novembro de 2026

VISÃO GERAL

Mesmas caixas, mesmo item

entrada

Base

Texto livre, 22 anos de deriva, seis plantas

23.554

materiais, PDM com 44 classes

passo 1

Classe

O grupo reduz 44 classes a 1–3; o substantivo decide

90,8%

acerto de classe

passo 2

Caixas

A classe define as caixas; regras e BERT as preenchem

97,5%

precisão dos atributos

passo 3

Árbitro

Tudo passa pela lista do PDM; acordo dá confiança

92,6%

cobertura do que o texto traz

passo 4

LLM

Só nas caixas em dúvida, nunca no dado ausente

3.482

itens para decisão humana

passo 5

Junção

Chave igual: código redundante

98,5%

precisão da junção

NA PLATAFORMA

Fila · **3.482 itens**

Juntados · **1.991 grupos**

NCM trocado · **1.104**

Radar · **R$ 30,24 mi**

fonte: artefatos/radar.json · docs/04-como-funciona.md

PRECEDÊNCIA NÃO É EXECUÇÃO

Toda camada que pode contribuir roda. A precedência resolve depois.

Quem ganha um empate é uma pergunta; quem roda é outra. Tratar as duas como a mesma coisa escondia divergências e produziu quatro bugs da mesma família.

fonte: docs/09-pipeline-correto.md §2

ORDEM DE EXECUÇÃO

As cinco fases

fase 1 **Coleta**	Cada camada aplicável propõe um candidato para cada caixa, sem saída antecipada.	sai: **0 a N candidatos por caixa**, com fonte e evidência
fase 2 **Validação**	Todo candidato passa pelo validador do PDM, venha de onde vier. O recusado vira termo para o dicionário.	sai: **candidatos válidos** e termos a canonizar
fase 3 **Arbitragem**	Concordam: aceita. Discordam: vence o mais forte e a caixa sobe. Nenhum válido: pendente.	sai: **ACEITO**, **CONFLITO** ou **PENDENTE**
fase 4 **Escalada**	O LLM entra só nas caixas não resolvidas, por termo distinto, e alimenta o dicionário aprendido.	sai: **valor escolhido entre alternativas**, validado de novo
fase 5 **Portão e saída**	Monta a descrição na ordem do PDM, resolve unidade e NCM e calcula a chave de identidade.	sai: **registro saneado e chave**, ou o motivo de não fechar

fonte: docs/09-pipeline-correto.md §3 · src/saneamento/pipeline.py

QUEM DECIDE · DA EVIDÊNCIA MAIS FORTE À MAIS FRACA

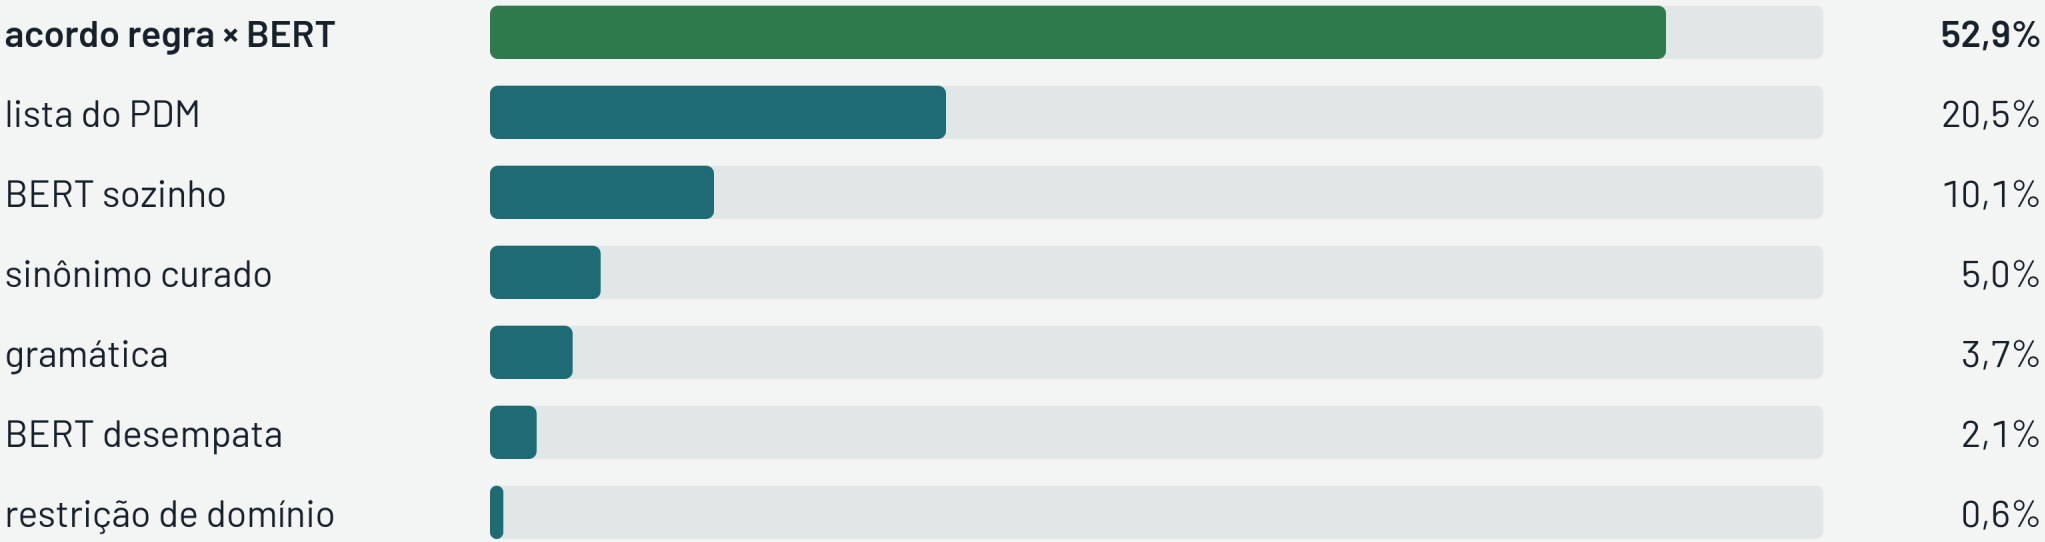
Onze camadas, ordenadas pelo que o cadastro escreveu

#	Camada	Exemplo	Quando roda
0	Rótulo no texto	DIAMETRO INTERNO:39MM	sempre
1	Lista do PDM	DIN 933 aparece literal e está na lista	sempre
2	Sinônimo curado	ACO CARB → ACO CARBONO	se 0 e 1 falham
3	Dicionário aprendido	BICROMATIZADO → ZINCADO AMARELO	se 0 a 2 falham
4	Gramática de grandeza	1960 psi → 135,1BAR	sempre, em caixa numérica
5	Restrição de domínio	alojamento > eixo > largura	quando a contagem casa
6	Regra 2 do PDM	M12X50 → BITOLA M12 + 50MM	sempre
7	Coluna do ERP	FABRICANTE = METSO	sempre
8	BERT	recorta qual trecho é de qual caixa	sempre
9	Embedding	trecho ≈ valor permitido, com margem	só propõe candidato
10	LLM	escolhe entre alternativas	só na escalada

fonte: docs/09-pipeline-correto.md §1 e §4

DE ONDE VEM CADA VALOR ACEITO

Metade dos valores vem de acordo entre regra e BERT

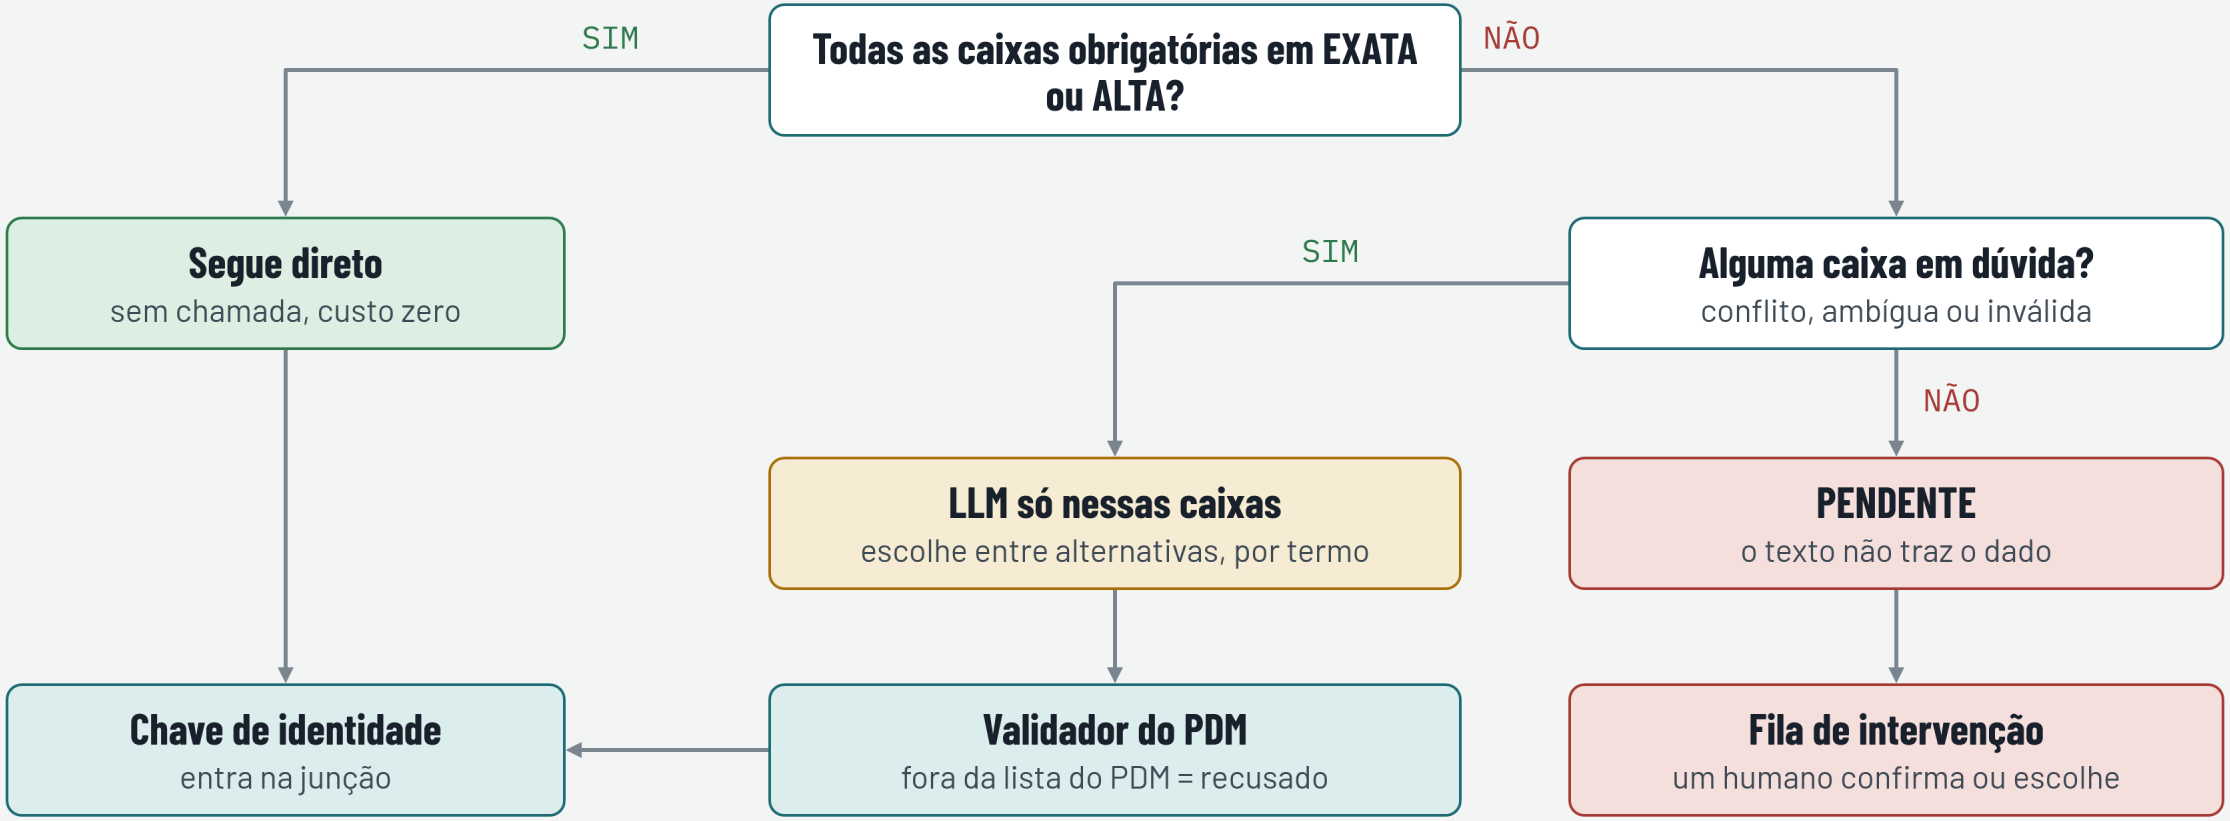


Esse sinal só existe porque o BERT roda mesmo quando a regra já achou o valor.

escala 0–60% · medição com o BERT ligado, antes das últimas correções · docs/00-estado-do-projeto.md §2

ESCALADA

Quando o LLM é chamado, e quando não é



fonte: docs/04-como-funciona.md §7 · src/saneamento/pipeline.py (ESTADOS_ESCALAVEIS)

BANDAS DE CONFIANÇA

A folga sobre o segundo lugar decide

Banda	Significa	Acontece
EXATA	o valor da lista estava escrito no texto	aceita, sem LLM
ALTA	similaridade alta e com folga sobre o 2º	aceita, sem LLM
BANDA_LLM	parece bater, mas sem folga	chama o LLM
BAIXA	não bate com nada	pendência
VAZIA	o texto não informa	pendência

Trava de gêmeo numérico

par que nunca pode confundir	similar.
INOX 304 × 316	0,963
ROSCA NPT × BSP	0,965
DIN 931 × 933	0,959

Se o 1º e o 2º colocados diferem só por um número, o embedding nunca decide.

fonte: docs/04-como-funciona.md §6

JUNÇÃO

Duplicidade é igualdade de chave

```
16220310 PARAFUSO SEXTAVADO, ROSCA:ROSCA GROSSA, ROSCA:M12, COMPRIMENTO:75,0MM, GRAU:8.8...
```

```
16686120 PARAFUSO SEXTAVADO; ROSCA: METRICA GROSSA; BITOLA: M12; COMPRIMENTO: 75MM...
```

caixa obrigatória	16220310	16686120
Rosca	METRICA GROSSA	METRICA GROSSA
Bitola	M12	M12
Comprimento	75MM	75MM
Classe resistência	8.8	8.8
Material	ACO CARBONO	ACO CARBONO
Acabamento	OXIDADO PRETO	OXIDADO PRETO
Norma	DIN 931	DIN 931

Chave idêntica nos dois

```
PDM001 | PARAFUSO | ROSCA=METRICA GROSSA | BITOLA=M12 | COMPRIMENTO=75MM | CLASSE=8.8 | MATERIAL=ACO CARBONO | ACABAMENTO=OXIDADO PRETO | NORMA=DIN 931
```

Mesma chave, mesmo item. Nenhum modelo opinou.

fonte: docs/04-como-funciona.md §8

JUNÇÃO

Duas formas de identidade e uma armadilha

Especificação técnica

42 classes: parafuso, válvula, cabo... Chave = classe + sujeito + **todas** as caixas obrigatórias.

Referência do fabricante

Filtros e sobressalentes, 37% da base. Chave = classe + sujeito + **fabricante + part number**.

Falta uma caixa: a chave não fecha

Sem material, um parafuso de aço carbono e um de inox ficariam iguais. A chave responde "não sei".

Equivalência não é duplicidade

`CAT 1R-1808 · DONALDSON P551808`

Intercambiáveis, mas dois produtos e dois contratos. A similaridade junta e erra; a chave separa, porque o fabricante faz parte dela.

fonte: docs/04-como-funciona.md §8 · regras 10 e 13 do PDM

CAMPOS VAZIOS · FABRICANTE, PART NUMBER, NCM

Regras primeiro, LLM só no resto

US$ 0

Regras e léxico

84,4%

acerto em part number

Part number é extração, não classificação. Em fabricante, acerta 99,9% do que cobre.

US$ 0

TF-IDF + regressão

91,1%

NCM top-1 · 98,9% top-3

Os 1.173 NCMs vazios preenchidos, com 3 minutos de treino.

US$ 20,45

LLM few-shot

12.909

fabricantes pelo Sonnet

Lista fechada e 3 exemplos. Antes dele, 2.765 saíram do léxico a custo zero.

fonte: README.md · preenchimento/08_preencher.py · preenchimento/saida/

BENCHMARK · 10 SOLUÇÕES × 4 CAMPOS · SPLIT CONGELADO

O vencedor quase sempre é o mais barato

solução · acerto top-1	Grupo	NCM	Fabricante	Referência	Custo
regras	96,2%	46,9%	73,9%	84,4% ★	$0
tfidf_lr	96,5%	91,1% ★	82,2%	6,1%	$0
llm_fewshot_sonnet	96,6% ★	87,3%	84,3% ★	81,2%	$15,26
llm_fewshot_fable	96,5%	90,4%	84,1%	82,6%	$69,54
llm_naive_sonnet	0,0%	42,7%	78,1%	80,6%	$8,00
llm_naive_fable	0,0%	76,7%	79,4%	79,7%	$72,22

O ganho está na lista fechada. Sem o vocabulário, o LLM faz 0,0% em grupo; com a lista e três exemplos, 96,6%.

Modelo maior não compensa. Em NCM, o modelo clássico de custo zero supera todas as LLMs.

★ vencedor do campo · fonte: preenchimento/benchmark.csv · custo total do benchmark US$ 173,62

RESULTADO · CAPITAL EM ESTOQUE

O plano de junção está pronto

Capital consolidável

R$ 30,24 mi

15,1% dos R$ 200,87 mi em estoque. 2.676 códigos a bloquear em 1.991 grupos.

Na fila de intervenção

R$ 10,84 mi

3.482 itens esperando decisão; 1.478 se resolvem com um clique.

Já consolidado

R$ 0,00

Nenhuma unificação foi executada no ERP ainda.

fonte: artefatos/radar.json · plano_juncao.csv · fila_intervencao.json

RESULTADO · MEDIDO EM GABARITO

O que está medido, e o que ainda não

Precisão das características

97,5%

IC 95% de 96% a 98%, em 1.131 rótulos

Junção: precisão / recall

98,5% / 97,0%

65 certas e 1 errada em 66 pares

Acerto de classe

90,8%

218 de 240 itens

Cobertura

92,6%

dos valores que o texto traz

Taxa de invenção · a melhorar

23%

19 de 84 ausentes preenchidos; 7% com as travas, só em replay

Determinismo

idêntico

2 execuções, 23.554 registros, nenhuma diferença

fonte: artefatos/radar.json (08/11/2026) · avaliacao/gold_*.csv · scripts/17_testar_determinismo.sh