Cadastro e saneamento de materiais com IA

Análise de mercado e do problema — Hackathon VX · Desafio 01

Equipe vxwinners · 07 de novembro de 2026

Baseado em MVP funcional com benchmark auditado (10 soluções × 4 campos, 23.554 itens)
e em 31 fontes externas verificadas individualmente por re-consulta em 07/11/2026.

Sumário executivo

Toda operação industrial intensiva em ativos depende de um cadastro de materiais — e ele apodrece: o mesmo item ganha vários códigos, descrições fogem do padrão, NCM e unidade saem errados e campos críticos ficam vazios. O briefing do desafio [32] resume as quatro contas que a bagunça gera: capital parado, compra fragmentada, operação parada e risco fiscal. Benchmarks independentes dão a escala: má qualidade de dados custa em média US$ 12,9 milhões por ano por organização (Gartner [11]) e 15%–25% da receita na estimativa de Thomas Redman (MIT SMR [12]).

Construímos um MVP que resolve o problema de ponta a ponta: classifica, deduplica, corrige NCM e preenche fabricante/part number combinando regras determinísticas, aprendizado de máquina clássico e LLM apenas onde ela paga o próprio custo — tudo medido num benchmark auditado com 10 soluções. Na base do desafio (R$ 200,9 mi de estoque), a solução destravou a identidade de R$ 101,2 mi em itens antes não-deduplicáveis e preencheu 35,3 mil campos por US$ 21 de computação.

Este relatório dimensiona o mercado (MDM global: US$ 21,6 bi em 2026 → US$ 50,9 bi em 2031 [1]), documenta casos reais de empresas nomeadas (CEMEX, Bruce Power, Bosch), modela a economia anual de R$ 5,7 mi a R$ 27 mi para uma empresa com estoque MRO de R$ 200 mi, e propõe precificação SaaS de R$ 180 mil a R$ 900 mil/ano — ancorada nos contratos reais de Informatica e Stibo [23,24] e em ROI mínimo de 10× para o cliente.

1. O problema: a base que todo mundo usa e ninguém confia

O cadastro de materiais é a fonte da verdade de compras, estoque, manutenção, recebimento e nota fiscal [32]. Ele se deteriora porque cada área cadastra do seu jeito, em texto livre, por décadas. Os quatro custos, nos termos do briefing [32]:

Dor	Mecanismo	Evidência externa
Capital parado	O mesmo item estocado sob vários códigos	9% das bases são duplicatas em média; 25% no caso Bosch [13,14]; 50–60% do estoque MRO típico é excedente/obsoleto/giro lento [10]
Compra fragmentada	Itens iguais comprados separados, sem escala	Catalogação otimizada reduziu 30% das despesas anuais de MRO em caso publicado [18]
Operação parada	Manutenção espera peça que já estava no almoxarifado	Compra emergencial custa 2–3× a planejada; até 90% das peças ficam paradas >1 ano [16]
Risco fiscal	NCM errado em milhares de itens	Multa de 1% do valor aduaneiro por classificação incorreta (MP 2.158-35/2001, art. 84) [22]

Medimos as quatro dores na base do desafio (23.554 itens da mineradora fictícia Serra Azul): 79% das descrições fora do padrão PDM; 19 unidades de medida onde o padrão admite 5; fabricante vazio em 66,5% e part number em 78,5% dos itens; R$ 31,4 mi imobilizados em itens bloqueados/obsoletos com saldo; R$ 9,5 mi de base fiscal exposta por NCM ausente ou divergente; e R$ 103,0 mi (metade do valor do estoque) em itens cuja identidade — fabricante + part number — estava incompleta, tornando a deduplicação impossível.

Há ainda um gancho estratégico: a Gartner projeta que 60% dos projetos de IA serão abandonados até o fim de 2026 por falta de dados prontos para IA [31]. Saneamento de cadastro deixou de ser higiene operacional: é pré-requisito para qualquer agenda de IA industrial.

2. Mercado endereçável

2.1 O mercado de software (TAM)

O mercado global de Master Data Management foi estimado em US$ 18,2 bi em 2025 e US$ 21,6 bi em 2026, com projeção de US$ 50,9 bi em 2031 (CAGR 18,7%) [1]. O mercado vizinho de ferramentas de qualidade de dados soma US$ 2,8 bi (2025) → US$ 7,4 bi (2031) [2]. Grandes empresas respondem por 63,3% da receita de MDM e a nuvem por 60,4% das implantações (2025) [1] — exatamente o perfil do nosso produto (SaaS para grandes operações).

2.2 O universo MRO que o produto arruma (contexto)

O setor de MRO é 'grande e fragmentado': só a Grainger, maior distribuidora da América do Norte, vendeu US$ 17,9 bi em 2025 com mais de 1,5 milhão de produtos estocados [3]; a Applied Industrial estima mercado endereçável de ~US$ 80 bi só na América do Norte [4]. O gasto com MRO representa 0,5%–4,5% da receita em manufatura, e manutenção consome 5%–20% do orçamento de uma planta [16]. A Verusen, análogo direto do produto, declara já ter analisado US$ 138 bi em gastos MRO de clientes [8].

2.3 O alvo imediato no Brasil (SAM/SOM)

Os segmentos do briefing [32] são grandes e concentrados no Brasil: a mineração faturou R$ 298,8 bi em 2025, com US$ 76,9 bi de investimentos previstos para 2026–2030 e atividade em 2.760 municípios [5]; a distribuição de energia tem 42 concessionárias atendendo 90 milhões de unidades consumidoras [6]; o saneamento investiu R$ 29,1 bi só em 2024 [7]. Somando petróleo & gás, papel & celulose e siderurgia, estimamos um universo de 150–300 operações no Brasil com estoque MRO relevante (R$ 50 mi a R$ 1 bi+ cada). Capturando 40 contas em 3 anos com ticket médio de R$ 400 mil/ano (seção 6), o SOM é de ~R$ 16 mi de receita recorrente anual — menos de 0,1% do TAM, premissa deliberadamente conservadora.

3. Casos reais: quem já paga essa conta

Casos publicados pelos próprios fornecedores de soluções (interpretá-los como resultados divulgados comercialmente, não auditoria independente — ainda assim, nomeiam empresas e cifras):

Empresa / setor	O que aconteceu	Resultado divulgado
Bruce Power (nuclear, Canadá)	Otimização de dados e estoque MRO com IA (Verusen)	US$ 42,2 mi identificados + US$ 18,1 mi adicionais [9]
CEMEX (cimento, 36 países)	900 mil cadastros de materiais em 6 ERPs tratados com IA (Creactives)	US$ 16 mi economizados; cadastro –20%; criação de itens novos –35% [21]
Bosch (autopeças)	Diagnóstico de duplicidade no material master (SpareTech)	25% do cadastro era duplicata; +50% de eficiência na checagem de spare parts [13,14]
Mineradora global (anônima)	Saneamento de 5 mi de registros, 50 mil duplicatas (PiLog)	US$ 30 mi (18 em manutenção + 12 em capital de giro); OEE +13 p.p. [20]
Mineradora de grande porte (anônima)	400 mil registros MRO com 10 mil duplicatas (PiLog)	US$ 35 mi+ de ganho; estoque –23% [19]
Petroquímica global (anônima)	65 mil registros avaliados em US$ 155 mi; 11 mil duplicatas (PiLog)	US$ 30,2 mi em capital desbloqueado [30]
Óleo & gás offshore (anônima)	Visibilidade de estoque entre unidades da frota (Verusen)	US$ 151 mi de oportunidade identificada; 10–20% de otimização de capital de giro [9]
Empresa global de nuvem (anônima)	Dado ruim no cadastro de compras	Pedido de compra de US$ 300 mil emitido para um único cabo [31]

Outras empresas nomeadas com programas ativos de governança de cadastro de materiais: Enel, Siemens, AB InBev, Gestamp, BorgWarner (Creactives [21]), Domtar (Verusen [9]), Brose e ElringKlinger (SpareTech [14]). Em pesquisa aberta não localizamos casos brasileiros publicados com números — o que sinaliza espaço de posicionamento pioneiro no país, não ausência do problema.

4. A solução e a evidência (MVP medido)

O MVP cobre as três frentes do briefing [32]: **saneamento** (deduplicação por chave de identidade após normalização), **cadastro** (API de sugestão em 19 ms integrada à interface: grupo, NCM, fabricante, referência e alerta de duplicata antes de criar o item) e **enriquecimento** (preenchimento dos campos vazios com confiança e origem por valor). A arquitetura usa LLM apenas onde há conhecimento de mundo a ganhar; o resto é determinístico e auditável. Benchmarkamos 10 soluções por avaliação mascarada (teste congelado de 1.500–2.000 itens/campo), com métricas recalculadas por verificador independente e auditoria de vazamento:

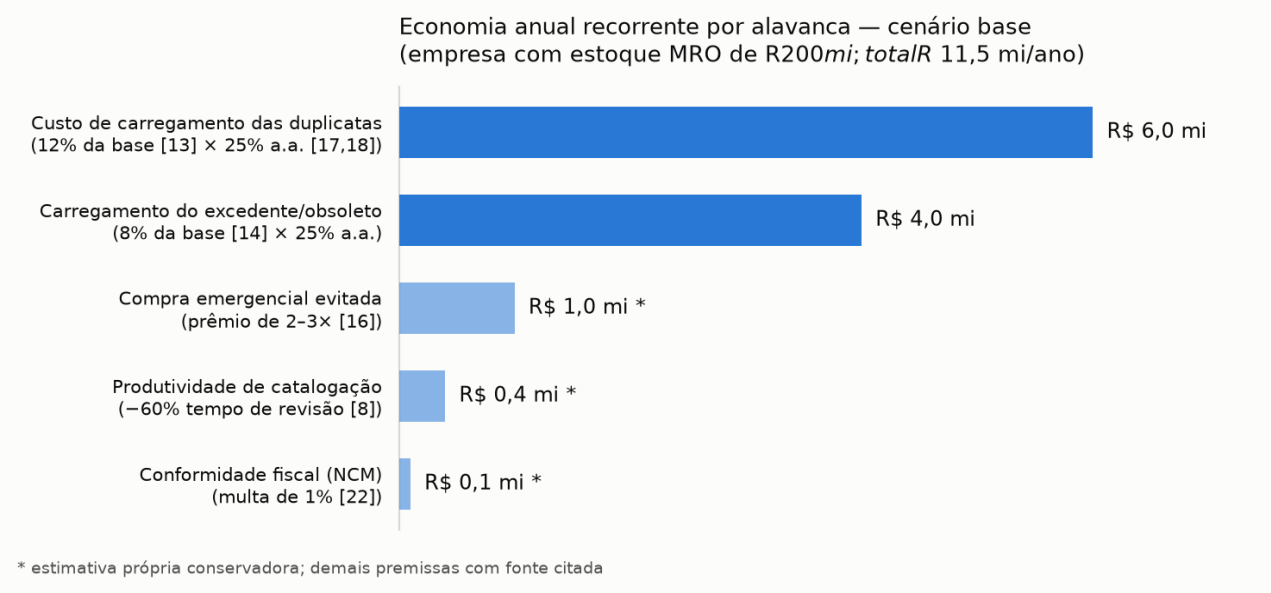
Campo	Melhor solução	Top-1	Top-3	Custo/1k itens	LLM ingênua (comparador)
Grupo de mercadoria	TF-IDF + regr. logística	96,5%*	97,2%	US$ 0	0% (não conhece códigos privados)
NCM	TF-IDF + regr. logística	91,1%	99,0%	US$ 0	42,7% (Sonnet) / 76,6% (Fable 5)
Fabricante	Cascata regras → LLM	84,3%	93,3%	US$ 0,51	78,1%
Part number	Extração por regras	84,4%	93,3%	US$ 0	80,6%

* teto imposto por ~3,5% de ruído plantado no gabarito do desafio; na inspeção manual dos erros, o NCM da própria base apoiou o modelo em 27 casos e o gabarito em 0.

Resultado aplicado à base Serra Azul: identidade (fabricante + part number) destravada em 5.055 dos 5.290 itens que valiam R$ 103,0 mi — **R$ 101,2 mi agora deduplicáveis**; 1.173 NCMs preenchidos (99% de acerto em 3 candidatos); 35,3 mil campos processados por **US$ 21** de computação, contra ~1.770 horas de trabalho manual equivalente. O modelo mais caro do mercado (Claude Fable 5, US$ 10/50 por MTok) foi testado e não liderou nenhum campo — evidência de que o gargalo é informação, não inteligência, e de que a arquitetura híbrida é a economicamente correta.

5. Quanto uma empresa economiza por ano

Modelo para uma empresa de referência com estoque MRO de R$ 200 mi (porte da Serra Azul; mineradoras e utilities médias/grandes). Cada premissa tem fonte; onde não há benchmark publicado, a linha está marcada como estimativa própria conservadora.



Alavanca (premissas com fonte)	Conservador	Base	Agressivo
Duplicatas na base: 9% / 12% / 25% [13,14] × custo de carregamento 20% / 25% / 30% a.a. [17,18]	R$ 3,6 mi	R$ 6,0 mi	R$ 15,0 mi
Excedente/obsoleto adicional identificado: 4% / 8% / 15% da base [14,10] × carregamento	R$ 1,6 mi	R$ 4,0 mi	R$ 9,0 mi
Compra emergencial evitada (prêmio 2–3× [16]) + produtividade de catalogação (–60% tempo [8]) + fiscal [22] — estimativa própria	R$ 0,5 mi	R$ 1,5 mi	R$ 3,0 mi
Economia recorrente total / ano	**R$ 5,7 mi**	**R$ 11,5 mi**	**R$ 27,0 mi**
Liberação de capital (one-off): redução de estoque de 10% / 20% / 30% [9,14,19]	R$ 20 mi	R$ 40 mi	R$ 60 mi

O modelo é coerente com os resultados divulgados pelo mercado: PiLog reporta 12–15% de redução de custo de estoque e casos de US$ 30–35 mi em mineração [19,20]; Verusen, 20% de redução líquida de capital de giro MRO e ROI de 10× no primeiro ano [8,9]; Verdantis, –30% de despesas anuais de MRO [18]. Projetos tradicionais de limpeza custam US$ 500 mil–2 mi+ em escala enterprise, demoram 3–12 meses e a base volta a sujar [10] — nosso produto substitui esse gasto recorrente por software contínuo com sugestão no momento do cadastro (a regra 1-10-100: prevenir custa 1, corrigir custa 10, ignorar custa 100 [13,31]).

6. Precificação do produto

6.1 Âncoras de mercado

Produto análogo	Preço observado	Modelo de cobrança
Informatica (MDM)	mediana US$ 56,3 mil/ano; faixa US$ 10,8–252,7 mil (36 contratos) [23]; relatos de US$ 160 mil a ~US$ 1 mi/ano [25]	nº de registros master + usuários; nuvem por consumo (IPU); manutenção 20–22%/ano [23]
Stibo Systems (STEP)	mediana US$ 97,4 mil/ano [24]	assinatura enterprise
SAP MDG	percebido como 'muito caro' [26]	por usuário/transação; nuvem por assinatura [26]
Semarchy xDM	posicionado abaixo de Informatica/Profisee [27]	por golden record [27]
Profisee	preço 'médio de mercado' (cotação) [28]	volume de registros, agnóstico a domínio [28]
Verusen (análogo direto)	assinatura anual; garantia de ROI mínimo de 3× [29]	assinatura + gain-share implícito via garantia [29]

6.2 Nossa proposta

Plano	Para quem	Assinatura	Inclui
Essencial	até 50 mil itens, 1 ERP	R$ 180 mil/ano	saneamento inicial + API de sugestão + painel de duplicatas
Profissional	até 250 mil itens	R$ 420 mil/ano	+ enriquecimento contínuo com LLM, fila de revisão, NCM fiscal
Enterprise	1 mi+ itens, multi-ERP	R$ 900 mil+/ano	+ integrações ERP, SLA, modelos dedicados, gain-share opcional

Racional: (i) **value-based** — o plano Profissional (R$ 420 mil ≈ US$ 75 mil/ano) captura menos de 4% da economia recorrente do cenário base (R$ 11,5 mi/ano), entregando ROI > 25× — acima da garantia de 3× da Verusen [29] e do ROI de 10× que ela divulga [9]; (ii) **ancoragem competitiva** — o ticket fica entre a mediana da Informatica (US$ 56 mil) e a da Stibo (US$ 97 mil) [23,24], abaixo dos relatos de ~US$ 1 mi/ano do MDM tradicional [25]; (iii) **cobrança por volume de itens**, o padrão do setor (Profisee, Semarchy) [27,28], transparente e alinhada ao valor; (iv) **implantação** (saneamento inicial assistido) cobrada à parte, a

0,8–1,2× a assinatura — substituindo projetos de limpeza de US$ 500 mil–2 mi [10] por entrega em semanas (nosso preenchimento completo custou US$ 21 de computação); (v) **gain-share opcional** no Enterprise: 10% da economia verificada no ano 1, com teto — espelha a assimetria de risco que o mercado já aceita [29]. Com 40 contas no mix (SOM, seção 2.3): ~R$ 16 mi de ARR no ano 3.

7. Riscos e limitações desta análise

(1) Vários benchmarks de economia vêm de material comercial de fornecedores (Verusen, PiLog, SpareTech, Verdantis) — são 'resultados divulgados', não auditorias; usamos sempre a ponta conservadora e marcamos estimativas próprias. (2) O MVP foi medido num dataset sintético realista do desafio; os tetos de acurácia (96,5% em grupo, 86,6% em part number) refletem ruído plantado e ausência real de informação — em bases reais os tetos variam. (3) Não localizamos casos brasileiros publicados com cifras; o mercado local pode exigir evangelização. (4) Preços de concorrentes vêm de marketplaces de contratos e relatos de usuários [23–28], não de tabelas oficiais. (5) A economia one-off (liberação de capital) depende de execução da consolidação física de estoque, não só do software.

Referências

Todas as URLs foram acessadas e verificadas individualmente em 07/11/2026 (re-consulta por verificador independente; apenas fontes confirmadas foram citadas).

[1] Mordor Intelligence — Master Data Management Market Size & Forecasts (2026–2031) — *pesquisa de mercado*. https://www.mordorintelligence.com/industry-reports/master-data-management-market

[2] Mordor Intelligence — Data Quality Tools Market (2026–2031) — *pesquisa de mercado*. https://www.mordorintelligence.com/industry-reports/data-quality-tools-market

[3] W.W. Grainger — Form 10-K FY2025 (SEC EDGAR) — *documento oficial*. https://www.sec.gov/Archives/edgar/data/277135/000027713526000011/gww-20251231.htm

[4] Applied Industrial Technologies — Form 10-K FY2025 (SEC EDGAR) — *documento oficial*. https://www.sec.gov/Archives/edgar/data/109563/000010956325000080/ait-20250630.htm

[5] IBRAM — Setor Mineral 2025 (apresentação oficial, fev/2026) — *entidade setorial*. https://ibram.org.br/wp-content/uploads/2026/02/02.02.2026-Setor-Mineral-2025.pdf

[6] ABRADEE — Associação Brasileira de Distribuidores de Energia Elétrica — *entidade setorial*. https://abradee.org.br/

[7] Instituto Trata Brasil — Principais estatísticas (SINISA) — *entidade setorial*. https://tratabrasil.org.br/

[8] Verusen — Duplicate Material Identification — *fornecedor*. https://verusen.com/duplicate-material-identification/

[9] Verusen — MRO Inventory Optimization (casos de clientes) — *fornecedor*. https://verusen.com/mro-inventory-optimization/

[10] Verusen — The Death of the Data Cleanse — *fornecedor*. https://verusen.com/the-death-of-the-data-cleanse/

[11] IBM Think — What is Data Quality? (cita pesquisa Gartner) — *fornecedor cita Gartner*. https://www.ibm.com/think/topics/data-quality

[12] MIT Sloan Management Review — Seizing Opportunity in Data Quality (T. Redman, 2017) — *acadêmico/independente*. https://sloanreview.mit.edu/article/seizing-opportunity-in-data-quality/

[13] SpareTech Blog — Find & Remove Duplicates in Your Material Master — *fornecedor*. https://sparetech.io/en/blog/find-and-remove-duplicates-material-master

[14] SpareTech — página principal (benchmarks e casos Bosch/Brose) — *fornecedor*. https://sparetech.io/en

[15] Harvard Business Review — Bad Data Costs the U.S. $3 Trillion Per Year (2016) — *acadêmico/independente*. https://hbr.org/2016/09/bad-data-costs-the-u-s-3-trillion-per-year

[16] Verdantis — MRO Spend Management, Analysis & Cost Reduction — *fornecedor*. https://www.verdantis.com/mro-spend-analysis/

[17] Wikipedia — Carrying cost — *referência geral*. https://en.wikipedia.org/wiki/Carrying_cost

[18] Verdantis — MRO Category Management (caso −30% despesas MRO) — *fornecedor*. https://www.verdantis.com/mro-category-management/

[19] PiLog — Case study: Inventory Management in Mining Industry — *fornecedor*. https://www.piloggroup.com/case-study/inventory-management-in-mining-industry/

[20] PiLog Group — resultados por setor e caso mineradora global — *fornecedor*. https://www.piloggroup.com/

[21] Creactives — Case study CEMEX: Material & Service Master Data — *fornecedor*. https://www.creactives.com/en/case-studies/cemex/

[22] Medida Provisória 2.158-35/2001, art. 84 — Planalto — *legislação*. https://www.planalto.gov.br/ccivil_03/mpv/2158-35.htm

[23] Vendr Marketplace — Informatica (benchmark de contratos) — *benchmark de preços*. https://www.vendr.com/marketplace/informatica

[24] Vendr Marketplace — Stibo Systems (benchmark de contratos) — *benchmark de preços*. https://www.vendr.com/marketplace/stibo-systems

[25] PeerSpot — Informatica MDM Pricing (relatos de usuários) — *avaliações de usuários*. https://www.peerspot.com/products/informatica-mdm-pricing

[26] PeerSpot — SAP Master Data Governance Pricing (relatos de usuários) — *avaliações de usuários*. https://www.peerspot.com/products/sap-master-data-governance-pricing

[27] PeerSpot — Semarchy xDM Pricing (relatos de usuários) — *avaliações de usuários*. https://www.peerspot.com/products/semarchy-xdm-pricing

[28] Profisee — página oficial de Pricing — *fornecedor*. https://profisee.com/pricing/

[29] Verusen — site oficial (modelo comercial e garantia de ROI) — *fornecedor*. https://www.verusen.com/

[30] PiLog — Case study: Inventory Management in Petrochemical Industry — *fornecedor*. https://www.piloggroup.com/case-study/inventory-manangement-in-petrochemical-industry

[31] Dataversity — Why Data Quality Is the Biggest Key to MDM Success (2026) — *imprensa especializada*. https://www.dataversity.net/articles/why-data-quality-is-the-biggest-key-to-mdm-success/

[32] Hackathon VX — Briefing do Desafio VX/D01: Cadastro e saneamento de materiais — *briefing oficial*. arquivo do desafio (PDF)